



Checklist de projetos de Aprendizado de Máquina

Um checklist simples para orientar seus projetos de Machine Learning (ML).

Adaptado do livro: “Hands-on Machine Learning with Scikit-Learn, Keras & TensorFlow”, Aurélien Géron (2022)

1 Definindo o Problema

Desafio

1. Forneça o **contexto** do problema.
2. Defina o **objetivo** em termos de negócios.

Definindo as baselines

1. Como o problema é resolvido atualmente e quais são os **ganhos** e **perdas**?

Planejamento da Solução

1. Que tipo de algoritmos de aprendizado de máquina (ML) usar(supervisionado/não supervisionado, online/offline, etc.)?
2. Como o desempenho deve ser medido?
3. Qual seria o desempenho mínimo necessário para atingir o objetivo de negócios?
4. Quais são as fontes de dados disponíveis?
5. Liste as premissas para o problema.
6. Como será o entregável do projeto?
 - Análise Exploratória de Dados, modelo de ML, ...

2 Obtendo os dados

1. Liste os dados que você precisa (e a quantidade).
2. Verifique as obrigações legais e obtenha autorização, se necessário.
3. Crie um espaço de trabalho com espaço em disco suficiente.
4. **Obtenha os dados.**
5. Dê uma olhada rápida na estrutura dos dados.
6. Converta os dados para um formato com o qual você possa trabalhar facilmente (sem alterar os dados em si).
7. Certifique-se de que as informações confidenciais sejam excluídas ou protegidas (por exemplo, anonimizadas).
8. **Selecione um conjunto de teste**, guarde-o e nunca mais olhe para ele (nada de bisbilhotar dados!).
 - Há situações em que os dados devem ser limpo primeiro (por exemplo, excluir instâncias com valores ausentes).

3 Limpeza de Dados

Nota: Você pode optar por inverter as etapas 3 e 4.

1. Converta os tipos adequadamente (por exemplo, string para datetime, string para numérico, ...)
2. Corrija ou **remova** outliers e instâncias duplicadas (opcional).
3. Preencha os **valores ausentes** (com zero, mediana, ...) ou exclua suas instâncias ou atributos.

5 Preparação dos Dados (Pré-processamento)

Nota:

- Trabalhe com cópias dos dados.
- Pode ser necessário limpar os dados novamente.

1. Seleção de atributos (opcional)
2. Engenharia de atributos, quando apropriado:
 - Discretize** os atributos contínuos.
 - Codifique** os atributos **categóricos**.
 - Adicione **transformações de atributos** (por exemplo, log(x), sqrt(x), x2, etc.).
 - Agregue os atributos** em novos atributos promissores.
- 3.Normalização de atributos:
 - Padronize ou normalize os atributos.

4 Explorando os Dados

Nota:

- Tente obter **insights** de um especialista da área primeiro.
- Pode ser necessário **limpar os dados** novamente durante esta etapa.

1. Crie uma cópia dos dados para exploração (reduzindo a amostra, se necessário).
2. Estude cada atributo e suas características:
 - Nome
 - Tipo (categórico, int/float, (ilimitado),texto, estruturado, etc.)
 - Ruído e tipo de ruído
 - Tipo de distribuição (uniforme, logarítmica, etc.)
1. Para tarefas de aprendizado supervisionado, identifique o(s)atributo(s) alvo.
2. Formule e valide hipóteses de negócios.
3. Visualize os dados.
4. Estude as correlações entre os atributos.
5. Identifique as transformações promissoras que você pode querer aplicar.
6. Documente seu aprendizado e conclusões.

7 Avaliação

Avaliação Técnica

1. Meça o desempenho dos modelos selecionados no **conjunto de teste** para estimar o erro de generalização.
 - Compare seus resultados com as baselines.

Avaliação em Termos de Negócios

- 1.O que o desempenho (técnico) reflete em **termos de negócios**?
 - Qual será o **impacto financeiro** do desempenho do sistema nos negócios?
 - Sua solução economizará **dinheiro e/ou tempo**?
- 2.**Quão benéfica** é sua solução (em termos de negócios) em comparação com as baselines?

8 Apresente sua solução

1. Destaque primeiro o **panorama geral**.
2. Explique por que sua solução atinge o **objetivo de negócios**.
3. Apresente os pontos interessantes que você observou:
 - Hipóteses** consideradas e os **5 principais insights**.
 - Descreva o que funcionou e o que não funcionou.
 - Suposições e limitações do sistema.
 - Resultados técnicos** e de **negócios**.
 - Principais **lições aprendidas** e próximos passos.

9 Implantação

1. Prepare sua solução para produção.
 - Conecte-se aos dados de produção, escreva testes, ...
- 2.**Implante** sua solução.
- 3.Escreva **código de monitoramento** para verificar o desempenho do seu sistema em tempo real em intervalos regulares e **acionar alertas** quando houver queda de desempenho.
- 4.**Retreine seus modelos** regularmente com novos dados (automatize o máximo possível).

6 Treinar Algoritmos de ML

Nota: Se os **dados** forem **muito grandes**, você pode querer amostrar **conjuntos de treinamento menores** para poder treinar muitos modelos diferentes em um **tempo razoável** (esteja ciente de que isso pode **penalizar** alguns modelos).

Selecionar Modelos Promissores

1. Treine muitos modelos rápidos e simples de diferentes categorias.
2. Meça e compare o desempenho deles no **conjunto de treinamento**:
 - Para cada modelo, use validação cruzada N-fold e calcule a média e o desvio padrão das N partições.
- 3.Analise as **variáveis mais significativas** para cada algoritmo.
- 4.Analise os **tipos de erros** que os modelos cometem.
- 5.Execute mais uma ou duas iterações rápidas das etapas anteriores.
- 6.Selecione os **três (a cinco) modelos mais promissores**, dando preferência a modelos que cometam diferentes tipos de erros.

Ajuste fino do sistema

- 1.**Ajuste** os **hiperparâmetros** usando validação cruzada:
 - Considere suas escolhas de **transformação de dados** como hiperparâmetros quando não tiver certeza sobre elas.
 - Use a **busca em grade** somente se houver **poucos valores de hiperparâmetros** para explorar; caso contrário, prefira a **busca aleatória**.
 - Se o treinamento for muito longo, você pode preferir uma abordagem de **otimização Bayesiana**.
- 2.Experimente **métodos de Ensemble**. Combinar seus **melhores modelos** geralmente apresenta um **desempenho melhor** do que executá-los individualmente.